Relatório: Apresentação da ERClinic

Tecnologias Inteligentes Aplicadas à Saúde | Eduardo C. Ceretta | UFN

A ERClinic é uma healthtech santamariense que há 11 anos ajuda clínicas e consultórios a gerirem melhor seus processos e pacientes por meio de um software web em modelo de assinatura mensal (SaaS). A análise de dados é usada na própria gestão e há um prontuário customizado.

1. Chatbot de agendamento

Chatbot para WhatsApp com atendimento 24h e agendamento automático. A ERClinic fornece API para integração com terceiros, usando RAG (consulta nos endpoints da API), prompt engineering e processos n8n (fluxo de agentes). Hoje o recurso é integrado com um parceiro, e a empresa deseja desenvolver um recurso próprio.

Avaliação:

Concordo com a aplicação. O agendamento é uma tarefa bem definida, e usar chatbot no WhatsApp com atendimento 24h faz sentido, porque o paciente já usa o aplicativo no dia a dia. Também concordo com o desejo de ter um recurso próprio: hoje a ERClinic depende de um parceiro, e ter a solução própria dá mais controle e reduz a dependência de fornecedor externo. Pelo que pesquisei em Google e Anthropic, o caminho comum é um fluxo mais fixo, com a IA entrando só nos passos que precisam dela, em vez de um agente totalmente livre. Isso deixa o agendamento mais previsível. Também seria importante prever a passagem da conversa para um humano e cuidar da LGPD, já que dados de saúde são dados pessoais sensíveis.

2. Alerta de risco de não comparecimento

Usa machine learning supervisionado (mineração de dados) para estimar a probabilidade de o paciente faltar. É um problema de classificação binária (compareceu ou não), treinado com dados históricos e estruturados da plataforma e resolvido com XGBoost, baseado em árvores de decisão combinadas (gradient boosting). Quando um agendamento é criado, o modelo retorna a probabilidade de falta, mostrada em faixas de risco. São usadas nove variáveis, como histórico e taxa de faltas, resultado da última consulta, convênio, teleconsulta, agendamento online, dia da semana e horário, e a importância das variáveis é avaliada, lembrando que correlação não implica causalidade. Um pipeline retreina o modelo com janela móvel de dois anos e o compara com o atual (ROC AUC, Average Precision e Brier Score). A ativação da nova versão depende de decisão manual.

Avaliação:

Concordo com a aplicação. Prever faltas com machine learning supervisionado, usando dados reais e estruturados da própria plataforma, é uma boa escolha, e o pipeline de retreino com janela móvel e comparação com o modelo atual segue o que o Google recomenda para MLOps. A ativação manual da nova versão também é uma validação a mais. Como melhoria, o desempenho poderia ser checado por grupos de pacientes, como faixa etária, convênio e teleconsulta, e não só na média, porque o modelo pode errar mais para alguns grupos. Variáveis como convênio merecem atenção, pois podem refletir condição social e gerar um tratamento desigual.

3. Transcrição da consulta

Hoje é feita por integração com parceiro: um widget grava a consulta e envia fragmentos de áudio ao servidor, que transcreve (speech-to-text), considera a especialidade, descarta conversas irrelevantes e usa LLM com prompt engineering para preencher cinco campos do prontuário (evolução, história da doença atual, hipótese diagnóstica, medicações e plano de tratamento). O profissional revisa. A ERClinic quer uma solução própria, por causa do custo da dependência de fornecedor externo, com RAG por especialidade. Avalia duas abordagens: enviar o áudio em fragmentos ao servidor ou transcrever no frontend e enviar só o texto, o que reduz dados e simplifica o servidor, mas depende do navegador ou dispositivo.

Avaliação:

Transcrever a consulta e organizar o conteúdo em campos do prontuário reduz o trabalho de digitação, e manter a revisão do profissional segue o que serviços como o AWS HealthScribe exigem. Entre as duas abordagens, me inclino pela de enviar o áudio em fragmentos ao servidor, porque ela controla o processamento e evita depender do reconhecimento do navegador, que em alguns casos, como o Chrome, envia o áudio a um servidor externo, o que pesa para dados de saúde. A transcrição no frontend continua válida se o protótipo mostrar boa qualidade e privacidade. Como melhoria, cada campo preenchido poderia apontar para o trecho da conversa que o originou, para facilitar a revisão.

4. Exames laboratoriais

O profissional envia foto ou PDF do exame. Uma LLM multimodal via OpenRouter interpreta o arquivo, com OCR (PyMuPDF e Tesseract) e prompt engineering, e devolve um JSON estruturado (schema de retorno) com valor, unidade, referência e classificação (normal, alto, baixo ou crítico), além de um parecer geral que não substitui a avaliação médica. Os resultados vão ao prontuário e a evolução aparece em gráficos. Um OCR local foi testado primeiro, mas o modelo multimodal pago funcionou melhor. Guardrails: não inventar dados ou diagnósticos, formato JSON obrigatório e tratamento de respostas inválidas.

Avaliação:

Usar LLM multimodal com OCR e schema de retorno é uma boa escolha para lidar com a mudança frequente de layout dos exames, e a ERClinic chegou a essa solução depois de testar um OCR próprio e perceber que o modelo multimodal pago funcionava melhor. O JSON obrigatório garante a estrutura da resposta, mas a documentação do Google avisa que isso não garante que o conteúdo esteja correto, e estudos de extração em laudos mostram erros que parecem válidos e são difíceis de perceber. Como melhoria, seria bom validar os valores automaticamente, mostrar ao profissional cada valor ao lado do trecho original do exame e enviar para revisão os campos de baixa confiança, como no fluxo com revisão humana da AWS. Assim, o parecer geral continua sendo apoio, e a decisão fica com o profissional.

5. Resumo do prontuário

LLM via OpenRouter com prompt engineering. Um algoritmo em Django percorre os módulos do prontuário (anamnese, evoluções, exames, prescrições, alergias e outros), organiza o histórico e o envia à LLM, que sintetiza por especialidade, elimina redundâncias e prioriza o mais recente. A resposta em JSON vira um resumo navegável com referência ao atendimento de origem, atualizado de forma incremental. Modelos de sumarização da Hugging Face foram testados, mas os modelos comerciais tiveram resultados melhores. Guardrails: proibir inventar informações, diagnósticos ou tratamentos, rastreabilidade e HTML gerado pelo sistema.

Avaliação:

Resumir o prontuário com LLM está alinhado com o que big techs fazem: a Epic, com tecnologia da Microsoft, tem uma ferramenta que condensa anos de notas em um resumo curto para revisão do clínico. Os pontos fortes da solução da ERClinic são a referência de cada informação ao atendimento de origem, parecida com a do AWS HealthScribe, e a atualização incremental, que evita reprocessar todo o histórico. Estudos mostram que LLMs podem resumir bem, mas ainda inventam e omitem informações, principalmente orientações de acompanhamento, então proibir inventar no prompt não basta. Como melhoria, seria bom avaliar a qualidade dos resumos com médicos e acompanhar quanto o profissional corrige, mantendo sempre o link para o registro original. O resumo deve ser apoio, e o profissional deve poder conferir a fonte.

6. Córtex, o copiloto clínico

Copilotos configuráveis, cada um com prompt, LLM e base privada de conhecimento (protocolos e diretrizes da clínica). Usa RAG em vez de retreinar o modelo: extração, chunking, embeddings (OpenAI text-embedding-3-small), base vetorial no Pinecone, busca semântica, reranking (Cohere Rerank) e geração por LLM (GPT-5 como exemplo e Gemini Flash). Guardrails: base isolada por copiloto, respostas fundamentadas que indicam quando falta informação, regras contra inventar medicamentos, doses ou condutas, saída em JSON e rastreabilidade dos trechos. O desafio é recuperar os trechos certos e avaliar se a resposta corresponde às fontes.

Avaliação:

Usar RAG em vez de retreinar o modelo faz sentido para os protocolos da clínica, porque os documentos podem ser atualizados sem treinar de novo, e a estrutura com embeddings, base vetorial e reranking segue as práticas atuais. A Anthropic mostra que combinar busca semântica com busca por palavras exatas e acrescentar contexto a cada trecho reduz as falhas de recuperação, o que poderia ser testado no Córtex. Um ponto de atenção é que citações podem passar falsa segurança: em um estudo com médicos, quando a IA errava mas parecia ter fonte, eles resistiam menos ao erro. Por isso, o Córtex deveria sinalizar quando a recuperação for fraca e mostrar o trecho que comprova a resposta, e a avaliação precisa medir se a resposta realmente corresponde à fonte, que é o desafio citado pela ERClinic.

7. Limitações, responsabilidade e regulação

A IA pode errar, reproduzir vieses e interpretar mal, e produzir resposta convincente que não está correta (IA não é verdade). O modelo precisa ser atualizado, como no exemplo do seguro de carro, em que idade e local de moradia entram como estatística e probabilidade. A IA analisa, organiza, sugere e acelera, e o profissional interpreta, contextualiza, decide e assume a responsabilidade: apoio à decisão, com decisão final do profissional. Quanto maior o impacto da decisão, maior a supervisão humana. Normas citadas: CFM (Resolução nº 2.454/2026, níveis de risco) e LGPD (dados de saúde são dados pessoais sensíveis). A solução precisa ser auditável e parametrizável.

Avaliação:

A regra de que a IA é apoio e o profissional decide está de acordo com a Resolução CFM nº 2.454/2026, que mantém o médico responsável pelos atos feitos com IA, e com a orientação da OMS de que as pessoas devem continuar no controle das decisões. A resolução também classifica os sistemas por risco: ferramentas administrativas, como chatbots de agendamento, têm risco baixo, e ferramentas que apoiam decisões sem agir sozinhas têm risco médio, o que parece ser o caso da transcrição, dos exames, do resumo e do Córtex. Como o uso de IA deve ser registrado no prontuário e informado ao paciente, seria bom a ERClinic permitir esse registro no sistema, além de manter logs de auditoria. Sobre a LGPD, dados de saúde são sensíveis, então usar dados de pacientes para treinar ou validar modelos exige cuidado, como anonimização e base legal adequada. Por fim, o risco de viés citado pela OMS reforça a ideia de checar o desempenho do modelo por grupos de pacientes.