Relatório: Apresentação da ERClinic

Tecnologias Inteligentes Aplicadas à Saúde | Eduardo C. Ceretta | UFN

A ERClinic é uma healthtech de Santa Maria que há 11 anos oferece um software web por assinatura (SaaS) para a gestão de clínicas e consultórios. Na apresentação, a empresa mostrou sete usos de IA ao longo da jornada do paciente. Para cada um, este relatório indica a técnica usada, o cenário em que ela aparece, uma avaliação e as alternativas.

1. Chatbot de agendamento

Técnica e cenário: chatbot no WhatsApp para atendimento 24h e agendamento automático. Usa LLM com prompt engineering, RAG que consulta os endpoints da API da ERClinic e fluxos no n8n. Hoje o recurso é de um parceiro, e a empresa quer desenvolver o próprio.

Avaliação: o agendamento é uma tarefa bem definida, e o WhatsApp é um canal que o paciente já usa. Ter uma solução própria reduz a dependência do parceiro. A Anthropic recomenda fluxos fixos, com a IA só nos passos que precisam dela, em vez de um agente totalmente livre, o que deixa o agendamento mais previsível [1]. Também é importante prever a passagem da conversa para um atendente humano e cuidar da LGPD.

Alternativa: function calling no lugar do RAG. Nessa técnica, o LLM não lê a agenda como texto: ele chama funções do sistema, como "consultar horários" e "marcar consulta", e o sistema executa e valida os dados. Faz mais sentido porque marcar uma consulta é uma ação que precisa ser exata, e não uma busca de informação. O CareConnect, um agente de agendamento em saúde, usa essa técnica com validação de cada parâmetro [2].

2. Alerta de risco de não comparecimento

Técnica e cenário: machine learning supervisionado para estimar a chance de o paciente faltar, como uma classificação binária (compareceu ou faltou), com XGBoost (várias árvores de decisão combinadas por gradient boosting). Usa nove variáveis da própria plataforma, como histórico e taxa de faltas, convênio, teleconsulta, dia e horário. O modelo é retreinado com os dados dos últimos dois anos, comparado com o atual (ROC AUC, Average Precision e Brier Score) e ativado só após decisão manual.

Avaliação: é uma boa escolha. Em cinco anos de consultas de um serviço de saúde, o XGBoost foi o melhor modelo, com AUC (área sob a curva ROC) de 0,92 [3]. O retreino com comparação segue a recomendação do Google para MLOps [4], e a ativação manual é uma validação a mais. Como melhoria, o desempenho deveria ser checado por grupos de pacientes (faixa etária, convênio, teleconsulta), e não só na média. Variáveis como convênio podem refletir condição social e levar a um tratamento desigual.

Alternativa: manter a regressão logística, um modelo estatístico mais simples, como base de comparação. Em um estudo da UCLA, a diferença para o XGBoost foi pequena (AUC de 0,82 contra 0,84) [5], e ela é mais fácil de explicar. Também vale usar SHAP, técnica que mostra quanto cada variável pesou no risco daquele paciente, para a recepção entender por que o alerta apareceu.

3. Transcrição da consulta

Técnica e cenário: reconhecimento de fala (speech-to-text) seguido de LLM com prompt engineering, que preenche cinco campos do prontuário (evolução, história da doença atual, hipótese diagnóstica, medicações e plano de tratamento) para o profissional revisar. Hoje é de um parceiro. A solução própria planejada inclui RAG por especialidade e avalia duas opções: enviar o áudio em partes ao servidor ou transcrever no navegador e enviar só o texto.

Avaliação: reduz o tempo de digitação, e a revisão do profissional segue o que serviços como o AWS HealthScribe exigem [6]. Entre as duas opções, eu escolheria enviar o áudio ao servidor, porque a ERClinic controla o processamento e não depende do reconhecimento do navegador, que no Chrome envia o áudio a um servidor externo, o que pesa para dados de saúde. Como melhoria, cada campo preenchido poderia apontar o trecho da conversa de onde saiu, como faz o próprio HealthScribe.

Alternativa: para o modelo próprio, usar o Whisper, modelo aberto de transcrição, rodando no servidor da ERClinic. Um estudo publicado pela SBC comparou modelos na transcrição de anamneses em português, e o Whisper teve o melhor resultado [7]. Também vale somar a diarização, que identifica quem falou (médico ou paciente) e já é usada junto com o Whisper em sistemas clínicos que rodam em servidor local [8].

4. Exames laboratoriais

Técnica e cenário: o profissional envia foto ou PDF do exame, e um LLM multimodal (que lê texto e imagem) via OpenRouter, com prompt engineering, devolve um JSON com valor, unidade, referência e classificação (normal, alto, baixo ou crítico), além de um parecer geral. Um OCR local foi testado antes, mas o modelo pago funcionou melhor.

Avaliação: é uma boa escolha para lidar com laboratórios que usam layouts diferentes, e a ERClinic chegou a ela depois de testar outra opção. Porém o JSON obrigatório garante só o formato: a documentação do Google sobre saída estruturada avisa que isso não garante que o conteúdo esteja certo [9]. Um estudo com exames laboratoriais mostrou que instruções contra alucinação reduzem os erros só em parte [10].

Alternativa: deixar o LLM só extrair os valores e fazer a classificação por código, comparando o número com a faixa de referência, já que uma comparação numérica não inventa resultado. Também vale mostrar cada valor ao lado do trecho original do exame e mandar para revisão os campos de baixa confiança, como no fluxo de revisão humana da AWS (Amazon A2I) [11].

5. Resumo do prontuário

Técnica e cenário: um algoritmo em Django reúne os módulos do prontuário (anamnese, evoluções, exames, prescrições, alergias e outros) e envia o histórico a um LLM via OpenRouter, que resume por especialidade, prioriza o mais recente e liga cada informação ao atendimento de origem. A atualização é incremental. Modelos da Hugging Face foram testados, mas os comerciais foram melhores.

Avaliação: segue o que as big techs fazem: a Epic, com tecnologia da Microsoft, oferece resumos de anos de notas para o médico revisar. Os pontos fortes são a ligação com o atendimento de origem e a atualização incremental, que evita reprocessar todo o histórico. Porém LLMs ainda inventam e omitem informações, principalmente orientações de acompanhamento [12], então proibir isso no prompt não basta.

Alternativa: não vejo uma técnica melhor. A ERClinic já testou a alternativa (modelos abertos de sumarização), e um estudo na Nature Medicine mostrou que resumos de LLMs adaptados foram iguais (45%) ou melhores (36%) que os de especialistas [13]. A melhoria está na avaliação: comparar os resumos com os de médicos, como nesse estudo, e medir quanto o profissional corrige.

6. Córtex, o copiloto clínico

Técnica e cenário: copilotos configuráveis, cada um com prompt, LLM e base privada com os protocolos da clínica. Usa RAG: divide os documentos em trechos, transforma cada trecho em embeddings (números que representam o significado), guarda no Pinecone, faz busca por significado, aplica reranking (uma segunda seleção, com Cohere Rerank) e gera a resposta com LLM (GPT-5 ou Gemini Flash), citando os trechos usados.

Avaliação: RAG faz sentido porque os protocolos mudam e podem ser atualizados sem treinar o modelo de novo. Um ponto de atenção é que as citações podem passar falsa segurança: em um estudo, quando o médico achava que a citação apoiava uma resposta errada da IA, ele abandonou a própria resposta correta em 15 de 23 casos [14]. Por isso, o Córtex deveria avisar quando a busca for fraca e mostrar o trecho exato que sustenta a resposta.

Alternativa: busca híbrida, que junta a busca por significado com a busca por palavras exatas (BM25). Nomes de remédios, doses e siglas precisam do termo exato, e a busca só por significado pode deixar esses trechos de fora. A Anthropic mostrou que essa combinação, com um pequeno contexto em cada trecho, reduz as falhas de busca [15].

7. Cervix (em desenvolvimento)

Técnica e cenário: visão computacional para um assistente de laudos de colposcopia: a IA marca regiões de interesse na imagem, e o profissional avalia e faz o laudo.

Avaliação e alternativa: manter o profissional na decisão final é o correto. Como a técnica não foi detalhada, as opções mais usadas são a U-Net, que marca a lesão ponto a ponto na imagem, e o YOLO, que detecta e contorna a lesão. Um modelo baseado em U-Net teve acurácia maior que colposcopistas especialistas em lesões CIN3+ (0,89 contra 0,85) [16].

Referências

[1] Anthropic. Building effective agents, 2024.

[2] CareConnect: Toward Trustworthy Large Language Model Agents in Healthcare. arXiv:2607.05055, 2026.

[3] Enhancing Health Equity by Predicting Missed Appointments in Health Care. JMIR Medical Informatics, 2024.

[4] Google Cloud. MLOps: Continuous delivery and automation pipelines in machine learning.

[5] UCLA. Estudo de preditores de falta em clínica de medicina esportiva (ML e regressão logística).

[6] Amazon Web Services. AWS HealthScribe, documentação.

[7] Gonçalves et al. Enhancing Automatic Speech Recognition Medical Transcriptions. JIDM (SBC), 2026.

[8] Toward Automated Clinical Transcriptions (Whisper e PyAnnote). PMC12150720, 2025.

[9] Google. Gemini API: Structured output, documentação.

[10] FSU. LabGenie: alucinação de LLMs na interpretação de exames laboratoriais, 2025.

[11] Amazon Web Services. Amazon Augmented AI (A2I), documentação.

[12] Hallucinations and Key Information Extraction in Medical Texts. arXiv:2504.19061, 2025.

[13] Van Veen et al. Adapted large language models can outperform medical experts in clinical text summarization. Nature Medicine, 2024.

[14] Large language models improve physician accuracy but lead to false reliance. arXiv:2608.00817, 2026.

[15] Anthropic. Introducing Contextual Retrieval, 2024.

[16] Dong et al. Classification and diagnosis of cervical lesions based on colposcopy images using deep fully convolutional networks. Fundamental Research, 2025.